

Trabajo Práctico 2: Árboles de Decisión



Introducción

En este trabajo vamos a utilizar la implementación de árboles de decisión de sklearn. Un ejemplo sobre el famoso dataset de iris es el siguiente:

```

from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.datasets import load_iris
from sklearn import tree
iris = load_iris()
X = iris.data
y = iris.target
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=0)
clf =
DecisionTreeClassifier(criterion="entropy", min_impurity_decrease=0.002, random_state=0, min_samples_leaf=5)
clf.fit(X_train, y_train)
tree.plot_tree(clf)
    
```

Trabajo Práctico 2: Árboles de Decisión

En el resto del práctico, a menos que se diga explícitamente lo contrario, **hay que crear los árboles con los parámetros mostrados en este código.**

- Realice algunas pruebas con esta implementación para familiarizarse con la misma.
- También una gráfica de los datos, en función de distintos pares de las variables originales, usando un color para cada clase predicha por el árbol.
- Busque el dataset correspondiente al problema Hypothyroid.
 - Obtenga un árbol de decisión a partir de los datos.
 - Analice los resultados.
- Una de las virtudes de los árboles, por la que son frecuentemente usados en problemas médicos, es que son "entendibles" en sus decisiones. Esto, ¿se aplica a este problema?.

Ejercicios

Entregar un notebook con el código (que incluya la generación de las gráficas) y texto con las discusiones pedidas.

Ejercicio 1. Árboles en Espirales.

Genere tres conjuntos de datos de entrenamiento correspondientes al problema de las espirales anidadas de la práctica de python:

- uno de longitud 150
- otro de 600
- y un tercero de 3000.

Genere un conjunto de test de longitud 10000.

A partir de cada uno de los conjuntos de entrenamiento, entrene el árbol de decisión correspondiente y grafique las predicciones sobre el conjunto de test.

Comente los resultados.

Ejercicio 2. Dependencia con la longitud del conjunto de entrenamiento - Sobreajuste.

Genere datasets usando el código "diagonal" desarrollado en la práctica de python (el otro conjunto desarrollado se llama "paralelo"), con $C = 0.78$ y $d = 2$.

Genere un único conjunto de test con $n = 10000$. Genere 20 conjuntos de entrenamiento para cada uno de los siguientes valores de n : **125, 250, 500, 1000, 2000, 4000**.

Trabajo Práctico 2: Árboles de Decisión

Entrene árboles sobre estos conjuntos y guarde los resultados de error (1-accuracy) sobre los datos de entrenamiento y sobre el conjunto de test, como así también el tamaño del árbol (atributo `tree_.node_count`).

En primer lugar genera una gráfica de las predicciones sobre los datos de test (plot x-y con colores para las clases) para un ejemplo de cada tamaño de conjunto de entrenamiento. Comente lo que se puede observar.

También genere dos gráficas: la primer gráfica tiene el training error y test error, y la segunda la cantidad de nodos en el árbol, todos como función de la longitud del conjunto de entrenamiento (utilice siempre el promedio de los 20 conjuntos de cada longitud dada). Sugerencia: usar escala logarítmica en el eje x, de la cantidad de datos.

Finalmente, repita todo el procedimiento completo usando como generador de datos el "paralelo". **Incluya los resultados correspondientes en las mismas gráficas del diagonal.** Discuta los resultados.

Ejercicio 3. Resistencia al ruido.

Genere datasets con **$d = 5$** , **$n = 250$** para el conjunto de entrenamiento y $n = 10000$ para el de test, variando el valor de **C** (overlapping de las clases) de **0.5 a 2.5 con incrementos de 0.5**. Como en el punto anterior, para cada valor dado de C cree 20 conjuntos distintos de entrenamiento, pero uno solo de test. Genere una gráfica del test-error en función de C para el problema "paralelo" y el "diagonal" (sólo los promedios de los 20 conjuntos para cada valor de C). También incluya en la gráfica los valores mínimos que se piden en el opcional 3.1 (el que no haga el opcional los puede pedir a la cátedra). **Todos los resultados de los dos problemas y el error mínimo en la misma gráfica.** Discuta los resultados.

Ejercicio 3.1 (Opcional, 1 punto):

Puede calcular para cada valor de C cuál es el mínimo error que se puede conseguir? Cómo se comparan dichos valores con los obtenidos con el árbol? Obtenga una curva de error mínimo y agréguela a la gráfica anterior. Explique brevemente cómo obtuvo los valores mínimos.

Hay varias maneras de hacerlo. Una simple es imaginando cuál es el clasificador ideal o de mínimo error para este problema (a ese clasificador se lo llama "clasificador de Bayes") y midiendo directamente sobre un conjunto de test grande (10000 puntos para $d=5$) cuántos puntos son mal clasificados por ese clasificador ideal. Para que verifiquen sus resultados, el error de Bayes para el diagonal con $C=1.00$ es 15.86%

Ejercicio 4. Dimensionalidad.

Genere datasets con **$C = 0.78$** , **$n = 250$** para el conjunto de entrenamiento y $n = 10000$ para el de test, variando esta vez el valor de d según la siguiente lista: **2, 4, 8, 16, 32**.

Trabajo Práctico 2: Árboles de Decisión

Para cada valor de d cree 20 conjuntos distintos de entrenamiento, y uno solo de test. Genere una gráfica del train y test error en función de d para el problema "paralelo" y el "diagonal" (**todos en la misma gráfica**). Discuta los resultados.

Ejercicio 5. XOR. (Opcional, 1 punto).

Baje de los archivos al problema XOR. Grafique las clases.

Observando el problema, indique cuál es el árbol más simple que clasifica correctamente todos los puntos.

Entrene ahora un árbol sobre este problema, y explique el resultado obtenido.